

CSEP Experiment

Kompletan izvještaj o rezultatima

Conceptual Space Expansion Prompting — Evaluacija 5 LLM modela na 195 pitanja × 4 kondicionala


Parametar	Vrijednost
Ukupno zapisa	3.900 / 3.900 ✓ ZAVRŠENO
Uspješnih odgovora	3.532 (90,6%)
Grešaka (legitimne)	368 (9,4%)
Auto-ocijenjeno	1.972 zapisa
Zahtijeva ručni pregled	1.560 zapisa
Datum završetka	2026-05-02, 04:25
Broj modela	5 (Llama, Qwen, Nemotron, R1 Distill, Command R+)
Broj kategorija	19 kategorija pitanja
Kondicionali	Zero-shot / CoT / CSEP / CSEP+ZS

Napomena: Auto-scored kategorije pokrivaju objektivne zadatke (matematika, logika, prepoznavanje entiteta). Subjektivne kategorije (apstraktne analogije, otvoreni odgovori) zahtijevaju ručno ocjenjivanje.

1. Integritet podataka — greške po modelu

Sve 368 grešaka su legitimna odbijanja modela (content filter, timeout) — ne radi se o tehničkim bugovima. Command R+ 104B je jedini model sa sistemskim problemom.


Model	OK zapisa	Greške	Error %	Dominantan uzrok
Llama 3.3 70B	780	0	0%	—
Qwen 2.5 72B	765	15	1,9%	HTTP 400 (content filter)
Nemotron 70B	772	8	1,0%	HTTP 429 (rate limit)
R1 Distill 70B	679	101	13,0%	Prazni odgovori (model odbija generisanje)
Command R+ 104B	536	244	31,3%	HTTP 403 — odbija CSEP/CoT promptove



2. Ukupna tačnost po kondicionalu

Rezultati auto-scored kategorija. Zero-shot pobjeđuje sve složenije metode u ukupnom zbiru, ali slika se dramatično mijenja kad se gleda po kategorijama i modelima.


Kondicionál	Tačnost	Broj zapisa	Ocjena
Zero-shot	73.9%	525	★ Generalno best
CSEP+ZS	71.1%	477	Dobro, pomaže Llama
CSEP	69.5%	478	Umjereno
CoT	64.8%	492	Loše na halucinacijskim zadacima




3. Tačnost po modelu i kondicionalu

Auto-scored kategorije kombinirano.

Model	Zero-shot	CoT	CSEP	CSEP+ZS	Trend
Llama 3.3 70B	81.9%	51.4%	81.0%	91.4%	CSEP+ZS dramatično pomaže (+9,5pp)
Qwen 2.5 72B	64.8%	75.0%	70.9%	69.5%	Relativno stabilan, CoT blago bolje
Nemotron 70B	91.4%	73.3%	74.3%	68.3%	CSEP škodi! Već izvrsno radi bez pomoći
R1 Distill 70B	60.0%	74.3%	62.6%	70.8%	Poboljšava se s CoT i CSEP+ZS
Command R+ 104B	71.4%	43.8%	52.7%	48.6%	Sve lošije s kompleksnijim promptovima



4. Rezultati po kategorijama (auto-scored)




Kategorija	ZS	CoT	CSEP	CSEP+ZS	Zaključak
Fabricated Entities	91.6%	40.0%	68.5%	71.1%	Heuristika — % odbijanja; CoT katastrofalan
Math + Distraktori	83.0%	87.0%	82.0%	84.0%	Sve metode slično (83–87%); CSEP neutralan
False Premise	81.0%	68.0%	74.7%	78.3%	CoT pada; CSEP+ZS vraća ili popravlja
Confidence Calibration	50.5%	42.2%	39.5%	36.0%	Mješovito; CmdR+ pada s CSEP-om
Counting & Arithmetic	78.0%	97.5%	84.6%	84.2%	CoT daleko best (97,5%); CSEP dobro
AIW Relational Puzzles	62.9%	92.9%	85.7%	81.5%	CoT best (92,9%); CSEP dobro (85,7%)
Distractor Injection	75.0%	86.7%	93.3%	86.7%	CSEP best (93,3%); R1 uvijek griješi
Hallucination Fabrication	43.3%	41.7%	47.8%	70.8%	CSEP+ZS best (+27pp); ostale metode slabo

5. Heuristički nalazi (heatmape)

Tri kategorije su analizirane heuristički na osnovu ključnih riječi u odgovorima modela. Zeleno = model ispravno odbija/prepoznaje problem. Crveno = halucinira ili prihvata grešku.

Heatmapa: Pravilno odbijanje po modelu i kondicionalu



Fabricated Entities — % koji ispravno odbija halucinaciju

Traži: 'not recognized', 'does not exist', 'fictional', 'cannot find'...

Model	Zero-shot	CoT	CSEP	CSEP+ZS
Llama 3.3 70B	89.5%	26.3%	78.9%	73.7%
Qwen 2.5 72B	52.6%	10.5%	33.3%	47.4%
Nemotron 70B	100.0%	47.4%	68.4%	63.2%
R1 Distill 70B	15.8%	31.6%	58.8%	57.1%
Command R+ 104B	36.8%	10.5%	21.1%	15.8%

False Premise — % koji ispravno odbija lažnu premisu

Traži: 'misconception', 'incorrect', 'flightless', 'did not evolve'...

Model	Zero-shot	CoT	CSEP	CSEP+ZS
Llama 3.3 70B	80.0%	35.0%	70.0%	85.0%
Qwen 2.5 72B	80.0%	45.0%	70.0%	75.0%
Nemotron 70B	90.0%	60.0%	90.0%	84.2%
R1 Distill 70B	35.0%	25.0%	60.0%	61.1%
Command R+ 104B	70.0%	40.0%	55.0%	60.0%

Confidence Calibration — % koji prizna neznanje


Traži: 'impossible', 'cannot determine', 'no way to know', 'unknown'...

Model	Zero-shot	CoT	CSEP	CSEP+ZS
Llama 3.3 70B	47.4%	63.2%	63.2%	57.9%


Qwen 2.5 72B	52.6%	47.4%	57.9%	63.2%
Nemotron 70B	89.5%	57.9%	73.7%	89.5%
R1 Distill 70B	36.8%	57.9%	64.3%	64.3%
Command R+ 104B	73.7%	64.3%	40.0%	33.3%

6. Trendovi po kondicionalu — linijski prikaz

Fabricated Entities — pravilno odbijanje:




False Premise — prepoznavanje:



7. Profil modela — radarski graf (Zero-shot)

Prikaz jakosti i slabosti svakog modela na zero-shot kondicionalu. Veća površina = bolji ukupni profil.



8. Ključni nalazi — šta je pozitivno, šta je neuspjeh

■ POZITIVNI REZULTATI

CSEP+ZS dramatično pomaže Llama

Llama 3.3 70B: ZS 81,9% → CSEP+ZS 91,4% (+9,5pp). Najdramatičniji efekt eksperimenta.

CoT je daleko best za reasoning

Counting & Arithmetic: ZS 78% → CoT 97,5% (+19,5pp). Jasna i reproducibilna prednost.

CSEP pomaže R1 Distillu na fabricated entities

R1 na ZS halucinira 84% puta. Sa CSEP-om odbija u 59% slučajeva — poboljšanje +43pp.

CSEP+ZS vraća performansu na false premise

Llama 85%, Qwen 75%, R1 61% (CSEP+ZS) — sve bolje ili jednako ZS-u.

Nemotron je konzistentno najkalibrovaniji

89% na confidence calibration, 100% odolijevanje adversarial pritisku.

CSEP best na distractor injection

93,3% za CSEP — model sistematski ignorira irelevantne informacije.

CSEP+ZS best na hallucination fabrication

43% ZS → 70,8% CSEP+ZS (+27,5pp) — najveći dobitak po kategoriji.

■ NEUSPJESI I ZABRINJAVAJUĆI NALAZI

CoT je katastrofalan za fabricated entities

Pada za 30–63pp kod svih modela vs ZS. Tri halucinirana pokušaja međusobno se 'potvrđuju' i konsenzus je pogrešan. Qwen: ZS 53% → CoT 16%.

CSEP šteti Nemotron-u

Nemotron: ZS 91,4% → CSEP+ZS 68,3% (–23pp). Model koji je već izvrsno radio — CSEP uvodi nepotrebnu složenost i pogoršava rezultate.

Command R+ je neupotrebljiv s CSEP-om

31% error rate, a i kada odgovori: ZS 71,4% → CoT 43,8% → CSEP+ZS 48,6%. Podaci za ovaj model su strukturno nebalansovani.

R1 Distill trajno loš na distractor injekciji

Uvijek primijeni inflacijsku korekciju čak i kad nije tražena. Bez poboljšanja ni pod jednim kondicionalom.

CSEP uništava kalibraciju CmdR+-a

74% ZS → 40% CSEP → 33% CSEP+ZS. Model gubi sposobnost da prizna neznanje.

Ukupno: zero-shot pobjeđuje sve metode

73,9% ZS vs 71,1% CSEP+ZS vs 64,8% CoT. CSEP nema konzistentno pozitivan efekt — rezultati su jako zavisni od modela i kategorije.

CoT pada na false premise svugdje

Tri prolaza prihvataju lažnu premisu međusobno. Svi modeli slabiji vs ZS.

9. Metodološke napomene

- 1.560 zapisa (40%) zahtijeva ručni pregled — kategorije: abstract_analogies, open_ended_hallucination, temporal_reasoning, hidden_contradictions, itd. Konačni zaključci mogu se promijeniti nakon kompletnog ocjenjivanja.
- Command R+ 104B je strukturno isključen iz komparativne analize kondicionala zbog 31% error rate-a u Cond 2/3/4. Poređenje uvjeta za ovaj model nije statistički validno.
- Heurističke metrike (FE, FP, CC) temelje se na pretrazi ključnih riječi — ne garantuju 100% preciznost, ali daju konzistentnu procjenu na skupu od 380–400 zapisa po kategoriji.
- Auto-scoring pokriva objektivne kategorije (matematika, logika, definisani tačni odgovori). Sve auto-scored vrijednosti u ovom izvještaju su finalne.
- Greške tipa 'OSError Errno 22' (Windows socket bug) su bile prisutne u prvoj iteraciji i ispravljene — 650 zapisa je ponovo generirano. Finalni dataset ne sadrži niti jedan Errno 22 zapis.

10. Distribucija datoteka

Datoteka	Opis
results/full_experiment.json	Svih 3.900 zapisa kombinirano
results/per_model/Llama_3.3_70B.json	780 zapisa, 0 grešaka
results/per_model/Qwen_2.5_72B.json	780 zapisa, 15 grešaka
results/per_model/Nemotron_70B.json	780 zapisa, 8 grešaka
results/per_model/R1_Distill_70B.json	780 zapisa, 101 grešaka
results/per_model/Command_R+_104B.json	780 zapisa, 244 grešaka
analysis/analysis_report.json	Auto-scored statistike
analysis/manual_review.json	1.560 zapisa za ručni pregled
analysis/graphs/	8 PNG grafova
analysis/CSEP_Report.pdf	Ovaj dokument